

DEEPFAKES FRENTE A VOCES DE GEMELOS IDÉNTICOS: UN ANÁLISIS ACÚSTICO PRELIMINAR

Eugenia San Segundo¹, Jonathan Delgado²

¹ Phonetics Laboratory, CSIC
{eugenia.sansegundo@csic.es}

² University of La Laguna
{extjdelgado@ull.edu.es}

Resumen

En este estudio preliminar, se eligió a dos parejas de gemelos varones idénticos (esto es, monocigóticos) de un corpus más amplio. Se establecieron dos criterios para seleccionarlos: (i) edad similar y (ii) distancia euclidiana similar entre cada hablante y su gemelo. Se analizaron acústicamente 12 muestras de voz, de unos 3-5 segundos de duración cada una, extraídas de conversaciones espontáneas semidirigidas. Las muestras analizadas comprenden dos muestras de voz natural por cada gemelo y otra muestra consistente en una voz clonada artificialmente con una herramienta comercial de clonación de voz mediante inteligencia artificial. Se analizaron con PRAAT un total de 21 parámetros acústicos relacionados con la calidad de voz. Los resultados preliminares muestran diferencias en el rendimiento de los parámetros acústicos, así como diferencias entre las parejas de gemelos.

Palabras clave: *deepfakes*, voz clonada, gemelos, análisis acústico

Abstract

In this preliminary study, we chose two pairs of identical (i.e. monozygotic, MZ) male twins from a larger corpus. Two main criteria were established in order to select the two most similar-sounding twin pairs from the corpus: (i) similar age and (ii) similar Euclidean distance between each speaker and his twin. We analyzed acoustically 12 voice samples, around 3-5 seconds long each, extracted from semi directed spontaneous conversations. There were two samples per twin member and a further voice sample consisting of an artificially cloned voice using a commercial AI voice cloning tool. A total of 21 acoustic parameters related to voice quality were analyzed using PRAAT. Preliminary results show parameter-dependent as well as twin-dependent differences.

Keywords: deepfakes, voice cloning, twins, acoustic analysis.

PACS n°.43.72.Ar, 43.72.Uv

1 Introducción

¿Las voces artificiales son ya indistinguibles de las voces humanas? Comprobar empíricamente qué hay de cierto en esta frase es lo que ha movido a algunos investigadores recientemente a comparar voces generadas por inteligencia artificial (IA) y voces humanas, con el objetivo de averiguar si existe algún parámetro vocal que nos permita distinguir fehacientemente voces reales de falsas. Ofrecer una respuesta científica a este tipo de preguntas es de gran relevancia social, ya que en los últimos años se han utilizado

voces similares a las humanas pero generadas por IA —esto es, *deepfakes* de voz— en diversos delitos [1-3].

Un *deepfake* es una voz sintética (generada a partir de modelos de aprendizaje profundo) que presenta un parecido extremo con una voz real y, por tanto, se puede usar para clonar voces y suplantar la identidad de un hablante. Los sistemas de biometría vocal son vulnerables a este tipo de ataques de suplantación de identidad (en inglés *spoofing attacks*). Estos desarrollos tecnológicos también ponen en serio peligro el uso de las grabaciones como prueba forense en el ámbito legal, por la dificultad de distinguir una voz real de un *deepfake*. Igualmente, los *deepfakes* se están utilizando para difamar a figuras públicas y hacerles emitir mensajes falsos, con el fin de influir en elecciones o en decisiones políticas. Así, cada vez se hace más difícil distinguir las noticias reales de las falsas y, por ello, existe una falta de confianza sin precedentes en los medios. Por tanto, es de suma importancia implementar una metodología que identifique cómo distinguir qué muestras de voz son *deepfakes*.

De lo expuesto hasta aquí se desprende que el uso indebido de los avances en IA está desencadenando un cambio de paradigma importante en una disciplina lingüística concreta: la fonética forense. Se trata de una subdisciplina de la lingüística que se ocupa de la aplicación de los conocimientos fonéticos a cualquier tipo de problema jurídico que implique grabaciones de voz o análisis de voz, desde el diseño de ruedas de reconocimiento de voz hasta los cotejos de voces, es decir, la comparación de una voz desconocida, perteneciente a un delincuente, con una o varias voces conocidas, pertenecientes a uno o varios sospechosos [4, 5]. Hasta ahora, los principales desafíos a los que se enfrentaban los fonetistas forenses eran la corta duración de las grabaciones de voz en algunos peritajes o a la degradación de la calidad de estas, debida al ruido de fondo o al propio canal de transmisión, entre otros factores [6, 7]. El mayor problema hoy en día ha pasado a ser si una grabación dubitada es real (es decir, producida por un humano) o ha sido generada artificialmente. Con todo, no está claro qué parámetros de voz deben analizar los expertos para responder a esta pregunta.

En cuanto a la elección de características vocales para la detección de un *deepfake*, los estudios experimentales realizados por diversos fonetistas hasta ahora presentan algunas limitaciones: o bien se trata de estudios demasiado preliminares, por ejemplo, estudios de caso (es decir, se analiza la voz de un único hablante, tanto su voz natural original, como su contraparte generada por IA [8]), o bien nos encontramos con estudios que exploran únicamente un tipo muy específico de parámetros, cuya elección se justifica porque se supone que funcionan adecuadamente para distinguir a hablantes distintos. Es decir, se conoce su rendimiento en un cotejo forense típico, que compara voces humanas [9]. Sin embargo, que un parámetro sea útil para distinguir dos voces humanas no quiere decir que sea útil también para distinguir una voz humana de una voz artificial. De ahí que sean necesarias nuevas investigaciones acústicas sobre esta cuestión.

Algunos estudios recientes examinan el estado de la cuestión en detección de ataques de suplantación de voz, que es el nombre que se utiliza en la literatura centrada en los sistemas de verificación automática de voz para referirse al tipo de ataques lanzados por un sujeto malintencionado para hacerse pasar ilegalmente por una persona autorizada en un sistema de reconocimiento de voz. Por ejemplo, en [10] se revisaron 172 artículos publicados entre 2015 y 2021 con el objetivo de analizar sistemáticamente el estado actual de las investigaciones en detección de ataques de suplantación de voz, proporcionando una taxonomía útil de los tipos de ataques que podemos identificar y los problemas que todos ellos comparten, además de resaltar direcciones futuras de trabajo en este ámbito. Por su parte, [11], en un estudio más reciente, aportan una revisión exhaustiva, en la que se señalan las diferencias clave entre los distintos tipos de *deepfakes* de voz, se describen y analizan conjuntos de datos disponibles, características acústicas analizadas, así como tipos de clasificaciones y métricas de evaluación, junto con una descripción de los enfoques metodológicos de última generación. Para cada aspecto, se discuten

las técnicas básicas, los últimos desarrollos y los principales desafíos. Además, estos autores realizan una comparación unificada de características y clasificadores representativos en los distintos conjuntos de datos para la detección de *deepfakes* de audio. Su estudio muestra que las investigaciones futuras deberían abordar la falta de conjuntos de datos a gran escala, la mala generalización de los métodos de detección existentes para ataques falsos de naturaleza desconocida, así como la interpretabilidad de los resultados de la detección.

Reconociendo la importancia de las revisiones de parámetros y métodos ya existentes, el objetivo de nuestro estudio es otro: se trata de comparar las características acústicas de la cualidad de voz de dos parejas de gemelos con las características acústicas de los *deepfakes* de sus propias voces. Como explicaremos en el siguiente apartado, con ese fin hemos extraído diversos parámetros acústicos que no se encuentran exactamente entre los parámetros descritos por [10] y [11], aunque algunos de los que usamos hacen referencia a la frecuencia fundamental, que los autores anteriores clasificarían como parámetros prosódicos.

2 Método

2.1 Participantes

Se eligió a dos parejas de gemelos varones idénticos (es decir, monocigóticos) del Corpus de Gemelos descrito en [12] (hablantes monolingües de la variedad de español peninsular estándar). Se establecieron dos criterios principales para seleccionar a las dos parejas de gemelos del corpus: (i) edad similar (20 y 28 años cada pareja) y (ii) distancia euclidiana similar entre cada hablante y su gemelo. Las distancias euclidianas se calcularon en un estudio previo [13] y están basadas en la evaluación perceptiva de su cualidad de voz mediante una versión simplificada del Análisis del Perfil Vocal (*Vocal Profile Analysis*, *VPA*) [14]. Las dos parejas de gemelos elegidas presentan un *Similarity Matching Coefficient* de 0.8, de un máximo posible de 1. Esto quiere decir que se asemejan perceptivamente en 8 de 10 ajustes articulatorios del VPA.

2.2 Muestras de voz y análisis acústico

Se analizaron acústicamente 12 muestras de voz, de unos 3-5 segundos de duración cada una. Las dos muestras de voz natural por cada gemelo (un total de 8 muestras) se extrajeron de conversaciones espontáneas semidirigidas. Se generó artificialmente otra muestra de voz para cada par de gemelos mediante una herramienta comercial de clonación de voz por IA desarrollada por la empresa *ElevenLabs*. En concreto, se utilizó la aplicación *Speech Synthesis (Text to Speech generation)*. A partir de un breve audio de entrenamiento y un texto, se genera una voz artificial que suena como la voz de entrenamiento reproduciendo exactamente el texto proporcionado. En general, se trata de frases declarativas, de distinta duración, que cada hablante había dicho realmente en la conversación espontánea; por ejemplo: “Por parte de mi padre son siete hermanos” o “Hacía un poco de aire y simplemente fue un tramo de cinco metros”.

Se analizaron con Praat un total de 21 parámetros acústicos relacionados con la cualidad de la voz. Se calculó: (i) la pendiente del LTAS (*LTAS slope*) y el Apha Ratio de cada muestra de voz y (ii) con los segmentos vocales de cada producción se calcularon: la frecuencia fundamental (F_0), así como, la variabilidad (F_0DS) y la pendiente media de la F_0 (F_0 *mean slope*), cinco parámetros de perturbación de la F_0 (jitter local, jitter absoluto, RAP, APQ5, DDP), seis parámetros de perturbación de la amplitud de la F_0 (shimmer local, shimmer absoluto, APQ3, APQ5, APQ11, DDA), tres parámetros relacionados

con el ruido aditivo en la señal de voz (HNR, CPPS, GNE), y los parámetros espectrales LTAS *slope* y Alpha Ratio. Los segmentos vocales de cada frase se extrajeron utilizando un script de Praat para la detección y extracción de segmentos vocales en el habla continua [15].

3 Resultados

En primer lugar, se realizó un análisis descriptivo donde se muestran los valores (media y desviación estándar) de las diferentes medidas acústicas en cada par de gemelos (par de gemelos 1= 1A y 1B; par de gemelos 2= 2A y 2B) en dos momentos (a = producción 1 y b = producción 2). Para estudiar las diferencias entre producciones reales y falsas se realizaron comparaciones no paramétricas con el estadístico U de Mann-Whitney con todos los parámetros acústicos. El análisis estadístico se realizó con el programa jamovi [16].

3.1 Frecuencia fundamental

En la tabla 1 se muestran los resultados descriptivos intrasujeto e intragemelo de los parámetros relacionados con la F0. En relación con la F0, se observa una pequeña variabilidad intrasujeto e intragemelo. La F0DS presenta una mayor variabilidad intragemelo en el par de gemelos 2. En el par de gemelos 1 se observa mayor variabilidad intrasujeto en la F0 *mean slope* en uno de los hermanos, así como una mayor variabilidad intragemelo.

Tabla 1 – Datos descriptivos: media (desv. estándar) de los parámetros relacionados con la F0

Condición	Muestra	F0	F0DS	F0 <i>mean slope</i>
Intrasujeto	1Aa vs. 1Ab	104.92 (4.36)	8.08 (1.56)	163.25 (14.23)
	1Ba vs. 1Bb	92.79 (3.94)	9.96 (0.69)	222.28 (57.31)
	2Aa vs. 2Ab	119.60 (4.22)	10.79 (5.21)	275.91 (19.52)
	2Ba vs. 2Bb	124.54 (5.27)	20.25 (0.74)	233.47 (17.88)
Intragemelo	1A vs. 1B	98.85 (7.78)	9.02 (1.46)	192.76 (48.20)
	2A vs. 2B	122.07 (4.83)	15.52 (6.24)	254.69 (28.87)

En las comparaciones entre producciones reales y falsas, se observa valores más bajos de F0 y F0 *mean slope*, así como una mayor variabilidad en las producciones reales (véase la figura 1). Los resultados de las comparaciones no paramétricas entre las producciones reales y las falsas no muestran diferencias significativas (véase la tabla 2).




Figura 1 – Comparación de los valores de la F0 y F0 *mean slope* entre voces reales y falsas

Tabla 2 – Comparaciones no paramétricas entre las producciones reales (n=8) y las falsas (n=4) en los parámetros de la F0

Parámetros	Grupo	Media (DE)	U	p
F0 (Hz)	Real	110.5 (13.78)	11	0.461
	Falsa	118.6 (10.74)		
F0DS (Hz)	Real	12.3 (5.45)	14	0.808
	Falsa	11.7 (4.55)		
F0 mean slope (Hz/s)	Real	223.7 (49.49)	14	0.808
	Falsa	238.9 (14.15)		

3.2 Parámetros de perturbación de la frecuencia

En la tabla 3 se muestran los resultados descriptivos de la variabilidad intrasujeto e intragemelo de los parámetros relacionados con la perturbación de la frecuencia. Ambos pares de gemelos tienen a un integrante con baja variabilidad intersujeto y el otro con una alta variabilidad intrasujeto en todos los parámetros de perturbación de la frecuencia, así como una variabilidad intragemelo alta.

Aunque no se encontraron diferencias significativas entre las producciones reales y las falsas (véase la tabla 4), se observan valores más bajos en las producciones reales respecto a las producciones falsas en todos los parámetros excepto en el jitter absoluto.

Tabla 3 – Datos descriptivos: media (desv. estándar) de los parámetros relacionados con la perturbación de la frecuencia

Condición	Muestra	Jitt local	Jitt abs	RAP	APQ5	DDP
Intrasujeto	1Aa vs. 1Ab	1.74 (0.06)	166.81 (12.60)	0.65 (0.13)	0.81 (0.13)	1.96 (0.40)
	1Ba vs. 1Bb	2.91 (0.87)	268.71 (40.85)	1.41 (0.54)	1.45 (0.52)	4.25 (1.61)
	2Aa vs. 2Ab	3.03 (0.87)	253.13 (64.32)	1.39 (0.46)	1.79 (0.64)	4.18 (1.40)
	2Ba vs. 2Bb	8.71 (0.04)	108.61 (11.41)	8.03 (0.04)	8.21 (0.00)	9.10 (0.11)
Intragemelo	1A vs. 1B	2.32 (0.84)	217.76 (63.79)	1.03 (0.54)	1.13 (0.48)	3.11 (1.63)
	2A vs. 2B	2.71 (0.62)	223.64 (80.81)	1.21 (0.33)	1.61 (0.42)	3.65 (1.01)

Tabla 4 – Comparaciones no paramétricas entre las producciones reales (n=8) y las falsas (n=4) en los parámetros de la perturbación de la frecuencia

Parámetros	Grupo	Media (DE)	U	p
Jitter local (%)	Real	2.52 (0.71)	16	1.00
	Falsa	2.64 (0.50)		
Jitter abs (µs)	Real	233.20 (79.42)	16	1.00
	Falsa	227.75 (65.55)		
RAP (%)	Real	1.13 (0.43)	14.5	0.86
	Falsa	1.23 (2.27)		
APQ5 (%)	Real	1.37 (0.49)	11	0.46
	Falsa	1.57 (0.28)		
DDP (%)	Real	3.38 (1.29)	15	0.93
	Falsa	3.69 (0.82)		

3.3 Parámetros de perturbación de la amplitud

En la tabla 5 se muestran los resultados descriptivos de la variación intrasujeto e intragemelo de los parámetros relacionados con la perturbación de la amplitud. Se observa en los dos pares de gemelos una baja variabilidad intrasujeto e intergemelo en todos los parámetros.

Tabla 5 – Datos descriptivos: media (desv. estándar) de los parámetros relacionados con la perturbación de la amplitud de la F0

Condición	Muestra	Shim local	Shim abs	PPQ3	PPQ5	PPQ11	DDA
Intrasujeto	1Aa vs. 1Ab	5.72 (1.04)	0.59 (0.09)	2.08 (0.38)	3.30 (0.53)	5.86 (1.23)	6.27 (1.16)
	1Ba vs. 1Bb	7.26 (0.67)	0.65 (0.02)	2.64 (0.50)	3.85 (0.62)	6.51 (0.76)	7.94 (1.52)
	2Aa vs. 2Ab	10.43 (2.77)	0.96 (0.28)	4.32 (0.88)	5.99 (1.37)	9.15 (1.40)	12.99 (2.64)
	2Ba vs. 2Bb	13.38 (2.25)	8.02 (0.14)	9.45 (0.98)	10.85 (1.95)	13.95 (3.67)	13.37 (2.94)
	1A vs. 1B	6.49 (1.14)	0.62 (0.06)	2.36 (0.48)	3.57 (0.56)	6.18 (0.91)	7.11 (1.46)
Intragemelo	2A vs. 2B	10.30 (2.06)	0.95 (0.18)	3.77 (0.99)	5.65 (1.43)	9.72 (2.36)	11.32 (2.98)

Las comparaciones entre producciones reales y falsas muestran valores más bajos en todos los parámetros de perturbación de la amplitud en las producciones reales (véase la figura 2) aunque las diferencias encontradas no son significativas (véase la tabla 6).




Figura 2 – Comparación de los valores del PPQ5 y PPQ11 entre voces reales y falsas

Tabla 6 – Comparaciones no paramétricas entre las producciones reales (n=8) y las falsas (n=4) en los parámetros de la perturbación de la amplitud

Parámetros	Grupo	Media (DE)	<i>U</i>	<i>p</i>
Shimmer local (%)	Real	8.39 (2.55)	11	0.461
	Falsa	9.70 (1.64)		
Shimmer abs (dB)	Real	0.78 (0.22)	12.5	0.610
	Falsa	0.85 (0.91)		
PPQ3 (%)	Real	3.06 (1.04)	10	0.368
	Falsa	3.60 (0.66)		
PPQ5 (%)	Real	4.61 (1.50)	9	0.283
	Falsa	5.72 (1.41)		
PPQ11 (%)	Real	7.95 (7.37)	9	0.283
	Falsa	10.01 (10.50)		
DDA (%)	Real	9.21 (3.13)	10	0.368
	Falsa	10.80 (1.99)		

3.4 Parámetros relacionados con el ruido aditivo en la voz

En la tabla 7 se pueden observar los resultados descriptivos intrasujeto e intragemelo de los parámetros relacionados con el ruido aditivo en la voz. Tanto la variabilidad intrasujeto como intragemelo es baja en los tres parámetros estudiados. Se encontraron valores más altos de HNR, pero valores más bajos, así como mayor variabilidad de CPPS y GNE en las producciones reales (véase la figura 3), aunque las diferencias no son significativas (véase la tabla 8).

Tabla 7 – Datos descriptivos: media (desv. estándar) de los parámetros relacionados con el ruido aditivo

Condición	Muestra	HNR	CPPS	GNE
Intrasujeto	1Aa vs. 1Ab	17.34 (0.29)	14.87 (0.38)	0.9 (0.01)
	1Ba vs. 1Bb	13.02 (0.70)	13.04 (0.44)	0.93 (0.00)
	2Aa vs. 2Ab	11.16 (1.73)	10.35 (0.21)	0.83 (0.00)
	2Ba vs. 2Bb	12.86 (2.47)	12.92 (1.46)	0.85 (0.00)
	1A vs. 1B	15.18 (2.52)	13.96 (1.11)	0.91 (0.02)
Intragemelo	2A vs. 2B	11.81 (1.89)	11.12 (1.22)	0.84 (0.01)




Figura 3 – Comparación de los valores de la CPPS y el GNE entre voces reales y falsas

Tabla 8 – Comparaciones no paramétricas entre las producciones reales (n=8) y las falsas (n=4) en el HNR, CPPS y GNE

Parámetros	Grupo	Media (DE)	<i>U</i>	<i>p</i>
HNR (dB)	Real	23.50 (2.74)	13	0.683
	Falsa	12.70 (0.69)		
CPPS(dB)	Real	12.54 (1.86)	11	0.461
	Falsa	13.19 (0.66)		
GNE	Real	0.88 (0.04)	11	0.442
	Falsa	0.90 (0.04)		

3.5 Parámetros espectrales

En la tabla 9 se muestran los resultados descriptivos de la variación intrasujeto e intragemelo de los parámetros espectrales. Se obtuvieron el LTAS slope y Alpha Ratio a partir de la muestra sin editar y tras extraer los segmentos vocales (LTAS *slope*-V y Alpha Ratio-V). Se observa una baja variabilidad intersujeto e intragemelo en todos los parámetros espectrales. Los valores de LTAS *slope* y Alpha Ratio presentan valores más bajos y menor variabilidad en las producciones reales, aunque estas diferencias no son estadísticamente significativas (véase la tabla 10).

Tabla 9 – Datos descriptivos: media (desv. estándar) de los parámetros espectrales

Condición	Muestra	LTAS slope	Alpha Ratio	LTAS slope-V	Alpha Ratio-V
Intrasujeto	1Aa vs. 1Ab	-25.79 (1.66)	-22.54 (1.64)	-26.13 (1.75)	-22.64 (1.74)
	1Ba vs. 1Bb	-22.78 (0.04)	-19.41 (0.09)	-22.88 (0.30)	-19.39 (0.31)
	2Aa vs. 2Ab	-25.67 (0.41)	-22.21 (0.41)	-25.92 (0.69)	-22.43 (0.69)
	2Ba vs. 2Bb	-22.11 (0.14)	-18.66 (26.39)	-22.24 (0.05)	-18.73 (0.05)
	1A vs. 1B	-24.28 (1.98)	-20.97 (2.04)	-24.50 (2.13)	-22.01 (2.14)
Intragemelo	2A vs. 2B	-23.89 (2.07)	-20.44 (2.06)	-24.08 (2.16)	-20.58 (2.17)

Tabla 10 – Comparaciones no paramétricas entre las producciones reales (n=8) y las falsas (n=4) en los parámetros espectrales

Parámetros	Grupo	Media (DE)	<i>U</i>	<i>p</i>
LTAS (Hz)	Real	-24.1 (1.89)	10	0.831
	Falsa	-23.7 (3.89)		
Alpha Ratio (Hz)	Real	-20.7 (1.92)	10	0.810
	Falsa	-20.3 (3.92)		
LTAS (parte vocálica) (Hz)	Real	-24.3 (2)	10	0.772
	Falsa	-23.8 (4)		
Alpha Ratio (parte vocálica) (Hz)	Real	-20.8 (2.01)	10	0.773
	Falsa	-20.3 (4.01)		

4 Discusión y conclusiones

El objetivo de este estudio preliminar ha sido comparar las características acústicas de la cualidad de voz de dos parejas de gemelos con las características acústicas de los *deepfakes* de sus propias voces. Para ello, se eligió a dos parejas de gemelos varones idénticos (monocigóticos) particularmente similares, de entre las voces recogidas para el Corpus de Gemelos descrito en [12]. Esta selección se justifica por el hecho de que no necesariamente todos los gemelos idénticos se parecen en todas sus características vocales [17]. Se eligió a la pareja A y B de gemelos por presentar un alto grado de parecido en la mayoría de sus ajustes articulatorios de cualidad de voz, analizada perceptivamente en estudios previos [14]. Se ha pretendido así que las comparaciones estadísticas entre voces reales y voces falsas que presentamos en el estudio (véase el apartado 3: Resultados), a partir del análisis de 21 parámetros acústicos, estuvieran basadas en los casos más extremos de parecido vocal en los seres humanos.

Los resultados se han dividido en cinco apartados en función del tipo de parámetros analizados: (i) parámetros relacionados con la F0, (ii) parámetros de perturbación de la frecuencia, (iii) parámetros de perturbación de la amplitud, (iv) parámetros relacionados con el ruido aditivo en la voz, y (v) parámetros espectrales. Para todos estos grupos de parámetros se ha analizado la variabilidad intrasujeto y la variabilidad intragemelo, por un lado (véanse las tablas 1, 3, 5, 7 y 9), y se han realizado comparaciones no paramétricas entre las producciones reales y las falsas (véanse las tablas 2, 4, 6, 8 y 10), por otro lado.

El análisis descriptivo de la variación intrasujeto e intragemelo (voces reales) revela que para la mayoría de los parámetros existe variabilidad intragemelar (que puede darse en las dos parejas de gemelos o solo en una), así como variabilidad intrasujeto. Esto hace que los gráficos de dispersión de las figuras 1-3 (que comparan voces reales con *deepfakes*) muestren que, para todos los parámetros, existe mayor dispersión siempre en las voces reales frente a los *deepfakes*. Estas diferencias son más pronunciadas en el grupo de parámetros relacionados con la F0 y menos pronunciadas en el grupo de parámetros relacionados con la perturbación de la amplitud. También observamos que, para todos los parámetros analizados, los valores son siempre más bajos en los *deepfakes* que en las voces reales, sin que en ningún caso estas diferencias sean estadísticamente significativas. A falta de una explicación para el hecho de que los valores sean sistemáticamente menores en las voces clonadas que en las naturales, sí encontramos pertinente destacar el hecho de que las voces humanas presentan variabilidad intrasujeto e intragemelar; se trata de una variación intra e interlocutor que está ausente en las voces artificiales y que podría ser un factor interesante a considerar en los cotejos de voces para explicar qué hace humana a una voz.

En cuanto a las limitaciones del estudio, la pequeña muestra de voces gemelares ha impedido realizar otro tipo de análisis estadísticos. En estudios futuros, cada voz de un gemelo podría compararse con su propio gemelo y con su *deepfake* para responder hasta qué punto un *deepfake* puede considerarse la voz más parecida a la voz de una persona y si es comparable a la similitud existente entre las voces de gemelos idénticos.

Finalmente, en la línea de [11], destacamos que es necesario mejorar la interpretabilidad de los resultados de la detección de *deepfakes*. Puesto que la mayoría de los detectores están basados en redes neuronales, no es fácil explicar qué parámetros de voz están detrás de esas redes neuronales profundas. Los resultados de nuestra investigación, aunque preliminares, pueden ayudar a arrojar cierta luz sobre cómo se distribuyen los distintos parámetros de voz cuando analizamos una voz natural y una voz falsa.

Fuentes de financiación

Proyecto PID2021-124995OA-I00 financiado por MICIU/AEI /10.13039/501100011033 y por FEDER, UE.

Referencias

- [1] Brewster, T. (2021). Fraudsters Cloned Company Director's Voice in \$35 Million Bank Heist, Police Find. *Forbes Magazine*. <https://www.forbes.com/sites/thomasbrewster/2021/10/14/huge-bank-frauduses-deep-fake-voice-tech-to-steal-millions/?sh=75dd610b7559>
- [2] Chivers, T. (2019). What do we do about deepfake video? *The Guardian*. <https://www.theguardian.com/technology/2019/jun/23/whatdo-we-do-about-deepfake-video-ai-facebook>
- [3] San Segundo, E. (2024). Profundizando en los deepfakes: ¿Qué hace humana a una voz? *Anuario AC/E 2024 de Cultura Digital* (pp. 28-41), Acción Cultural Española (AC/E).
- [4] Jessen, M. (2008). Forensic phonetics. *Language and linguistics compass*, 2(4), 671-711.
- [5] Jessen, M. (2018). Forensic Voice Comparison. En: Visconti, J. (ed.). *Handbook of Communication in the Legal Sphere*. Berlín: De Gruyter Mouton.
- [6] Eriksson, A. (2005). Tutorial on forensic speech science. En: *Proc. European Conf. Speech Communication and Technology* (pp. 4-8).
- [7] French, P. & Stevens, L. (2013). Forensic speech science. En: Jones, M. J. y Knight, R. A. (eds.). *Bloomsbury companion to Phonetics* (pp. 183-197). Londres: Continuum.
- [8] Jiménez-Peña, J., Torres-Castillo, F.A., & Cueva-Sánchez, O. E. (En prensa). Comparación forense de voces: un estudio preliminar sobre las diferencias entre una voz natural y una voz artificial para la investigación judicial. *Revista Oficial del Poder Judicial. Órgano de Investigación de la Corte Suprema de Justicia de la República del Perú*.
- [9] Pellegrino, E., Kathiresan, T., Roswandovitz, C., Fruholz, S., & Dellwo, V. (2019). Can prosody be the key to spot fake voices? Acoustic and automatic speaker verification analyses on digital and natural voices, *The 28th Conference of the IAFPA*, Estambul (Turquía), 14-17 julio de 2019.
- [10] Tan, C.B., Hijazi, M.H.A., Khamis, N., Zainol, Z., Coenen, F., & Gani, A. (2021). A survey on presentation attack detection for automatic speaker verification systems: State-of-the-art, taxonomy, issues and future direction. *Multimedia Tools and Applications* 80 (21), 32725–32762.
- [11] Yi, J., Wang, C., Tao, J., Zhang, X., Zhang, C. Y., & Zhao, Y. (2023). Audio deepfake detection: A survey. *arXiv preprint arXiv:2308.14970*.
- [12] San Segundo, E. (2013). A phonetic corpus of Spanish male twins and siblings: Corpus design and forensic application. *Procedia - Social Behav. Sci.*, 95, 59-67.
- [13] San Segundo, E., Foulkes, P., & Hughes, V. (2016). Holistic perception of voice quality matters more than L1 when judging speaker similarity in short stimuli. In *Proceedings of the 16th Australasian Conference on Speech Science and Technology* (pp. 309-312).
- [14] Laver, J. (1980). *The Phonetic Description of Voice Quality*, Cambridge University Press.
- [15] Maryn, Y., Corthals, P., Van Cauwenberge, P., Roy, N., & De Bodt, M. (2010). Toward improved ecological validity in the acoustic measurement of overall voice quality: combining continuous speech and sustained vowels. *Journal of Voice*, 24(5), 540-555.
- [16] The jamovi project (2023). *jamovi*. (Version 2.4) [Computer Software]. Retrieved from <https://www.jamovi.org>.
- [17] San Segundo, E. (2014). *Forensic speaker comparison of Spanish twins and non-twin siblings. A phonetic-acoustic analysis of formant trajectories in vocalic sequences, glottal source parameters and cepstral characteristics*. Doctoral Dissertation, Consejo Superior de Investigaciones Científicas & Universidad Internacional Menéndez Pelayo.